

Simultaneidade Lambda

Reserved e Provisioned Concurrency

AWS Certified Developer Associate

Instrutor: Marlon Anesi

Conceito de Simultaneidade

Concurrency = Número de execuções simultâneas da função

- Limite default da conta: 1.000 execuções simultâneas
- Compartilhado entre TODAS as funções da região
- Pode solicitar aumento via Service Quotas
- Se exceder: throttling (HTTP 429)

Visualização:

Limite da Conta: 1.000 (compartilhado)

Func A: 400

Func B: 300

Func C: 200

Disponível: 100

Reserved Concurrency

Reserved Concurrency = Capacidade GARANTIDA para uma função

Características:

- Reserva capacidade exclusiva do pool da conta
- Nenhuma outra função pode usar essa capacidade
- Também funciona como LIMITE máximo
- Sem custo adicional!

Quando Usar

- Garantir capacidade crítica
- Proteger funções importantes
- Limitar funções que podem sobrecarregar backend

Atenção!

- Reserved = 0 -> função DESABILITADA
- Reduz pool disponível p/ outras
- Throttle se exceder o reservado
- Não elimina cold starts!

Provisioned Concurrency

Provisioned Concurrency = Ambientes PRE-INICIALIZADOS

Características:

- Elimina cold starts completamente
- Ambientes ficam WARM e prontos
- Ideal para latência consistente
- **TEM CUSTO ADICIONAL! (paga enquanto provisionado)**

Característica	Reserved	Provisioned
Propósito	Garantir/limitar capacidade	Eliminar cold start
Cold Start	Ainda ocorre	Eliminado
Custo	Sem custo extra	Custo adicional
Aplica-se a	Função (\$LATEST)	Versão/Alias específico


Auto Scaling de Provisioned Concurrency

Use Application Auto Scaling para ajustar automaticamente!

Configurações:

- Target Tracking: Mantem utilização em X% (ex: 70%)
- Scheduled Scaling: Aumenta em horários de pico
- Combinar com CloudWatch Alarms

Exemplo: E-commerce - Black Friday



Scheduled Scaling: Aumenta provisioned antes do pico, reduz depois!



Pontos-chave para a Prova

1. Concurrency Default

- 1.000 por região (compartilhado)
- Exceder = throttling (429)

2. Reserved Concurrency

- GARANTE capacidade (e limita)
- Reserved = 0 -> função desabilitada
- SEM custo adicional, MAS tem cold start

3. Provisioned Concurrency

- ELIMINA cold start
- TEM custo adicional
- Use com Auto Scaling para otimizar custo

LEMBRE-SE: Cold start? Provisioned. Garantir capacidade? Reserved!