

Throttling, Quotas e Caching

Controle de Tráfego e Performance

AWS Certified Developer Associate

Instrutor: Marlon Anesi

Throttling no API Gateway

O que é Throttling?

Limite de requisições por segundo para proteger backend de sobrecarga.

Limites Padrão (região)

- 10.000 requisições por segundo (steady-state)
- 5.000 requisições de burst (pico momentâneo)

Níveis de Throttling

- 1. Conta AWS: limite global por região
- 2. API/Stage: limite por stage específico
- 3. Método: limite por método específico (GET /users)

Erro ao Exceder

Cliente recebe: 429 Too Many Requests

Deve implementar retry com exponential backoff

Usage Plans e API Keys

Usage Plans

Definem limites de uso para clientes específicos através de API Keys.

Componentes de Usage Plan

- Throttle: requisições por segundo (rate limit)
- Quota: requisições por dia/semana/mês
- Burst: pico de requisições permitido

API Keys

- Identificadores únicos para clientes
- Associados a Usage Plans
- Enviadas no header x-api-key

Casos de Uso

- APIs públicas com planos (Free, Basic, Premium)
- Controlar acesso de parceiros/clientes
- Monetização de APIs

Caching no API Gateway

O que é Cache?

Armazena respostas temporariamente para reduzir latência e carga no backend.

Configuração

- Habilitado por stage
- Tamanho: 0.5 GB a 237 GB
- TTL (Time To Live): 0 a 3600 segundos (padrão 300s)

Cache Key

Formada por: método HTTP, path, query strings, headers

- Cache por query string: ?userId=123
- Cache por header: Accept-Language

Invalidação

- Automático: após TTL expirar
- Manual: Flush entire cache (console/API)
- Por requisição: header Cache-Control: max-age=0

Boas Práticas e Custos

Boas Práticas

Throttling:

- Configure limites conservadores
- Ajuste conforme carga real

Caching:

- Use para dados que mudam pouco
- TTL baseado em frequência de mudança
- Não cache dados sensíveis

Custos

Throttling:

- Incluído sem custo adicional

Caching:

- Cobrado por hora por GB
- Varia conforme tamanho do cache
- Pode compensar com redução de chamadas backend

Quando Não Usar Cache

- Não use cache para dados em tempo real ou que mudam frequentemente
- Não cache dados específicos por usuário (use com cuidado)
- Não cache se latência de backend já é muito baixa
- Não cache respostas de POST, PUT, DELETE (apenas GET)



Pontos-chave para Revisão

1. Throttling

- Padrão: 10.000 req/s steady-state, 5.000 burst
- Níveis: conta > API/stage > método
- Exceder: erro 429 Too Many Requests

2. Usage Plans e API Keys

- Throttle + Quota + Burst por cliente
- API Key no header x-api-key

3. Caching

- TTL: 0 a 3600 segundos (padrão 300s)
- Apenas GET (nunca POST/PUT/DELETE)
- Invalidação: TTL, flush manual, Cache-Control header

LEMBRE-SE: Se menciona 'limitar requisições' ou '429 erro' > Throttling! Se menciona 'reduzir latência' > Cache!