

Amazon Kinesis

Data Streams e Firehose para Streaming de Dados

AWS Certified Developer Associate

Instrutor: Marlon Anesi

O que é Amazon Kinesis?

Plataforma gerenciada para coleta, processamento e análise de dados em tempo real

Data Streams

Captura e armazena streams de dados para processamento customizado

Data Firehose

Entrega dados para destinos como S3, Redshift, OpenSearch de forma automática

Data Analytics

Processa streams usando SQL ou Apache Flink em tempo real

Video Streams

Captura e processa streams de video para ML e analytics

Foco do DVA-C02: Data Streams e Data Firehose

Kinesis Data Streams

Conceitos Fundamentais:

Shards: Unidade de capacidade (1 MB/s entrada, 2 MB/s saída)

Records: Unidade de dados (max 1 MB por record)

Partition Key: Determina em qual shard o record vai


Retention: 24h (padrão) ate 365 dias

Modos de Capacidade:

On-Demand

Escala automaticamente. Sem planejamento.
Paga por GB de dados lidos/escritos.

Arquitetura Data Streams



Provisioned

Você define número de shards.
Paga por shard/hora.

Kinesis Data Firehose

Serviço totalmente gerenciado para entrega de dados em near real-time

Características Principais:

- **Sem gerenciamento de shards** (serverless)
- Escala automaticamente com volume de dados
- Near real-time (buffer de 1-15 min ou 1-128 MB)
- Transformação de dados com Lambda
- Conversão de formato (JSON para Parquet/ORC)
- Compressão automática (GZIP, Snappy, etc.)

Destinos Suportados:

Amazon S3 - Data lake

Amazon Redshift - Data warehouse

Amazon OpenSearch - Analytics/Search

HTTP Endpoint - APIs terceiros

Splunk - Observabilidade

Datadog/New Relic - Monitoring

IMPORTANTE: Firehose NÃO permite consumers customizados. Se precisa processar dados com sua lógica, use Data Streams.

Data Streams vs Data Firehose

Característica	Data Streams	Data Firehose
Gerenciamento	Shards manuais ou On-Demand	Totalmente gerenciado
Latência	Real-time (~200ms)	Near real-time (1-15 min)
Consumers	Múltiplos, customizados	Destinos pre-definidos
Retenção	24h a 365 dias	Sem retenção (entrega imediata)
Replay de dados	Sim (dentro da retenção)	Não
Transformação	Via consumers	Lambda integrado
Caso de uso	Processamento customizado	ETL para data lake/warehouse

Pontos-chave para o Exame

1. Kinesis Data Streams

- Shards: 1 MB/s entrada, 2 MB/s saída por shard
- Retenção: 24h (padrão) ate 365 dias
- Permite múltiplos consumers customizados

2. Kinesis Data Firehose

- Totalmente gerenciado (serverless)
- Near real-time (buffer 1-15 min)
- Destinos: S3, Redshift, OpenSearch, HTTP, Splunk

3. Quando usar cada um

- Data Streams: processamento customizado, baixa latência
- Firehose: ETL para data lake, sem gerenciamento

LEMBRE-SE: Se precisa de 'streaming de dados em tempo real' > pense Kinesis Data Streams. Se precisa 'carregar dados para S3/Redshift' > pense Firehose!