

Amazon Athena

Queries SQL Interativas em Dados no S3

AWS Certified Developer Associate

Instrutor: Marlon Anesi

O que é Amazon Athena?

Serviço serverless de query interativa para analisar dados no S3 usando SQL padrão

Características Principais

- Serverless (sem infra para gerenciar)
- SQL padrão (Presto/Trino)
- Consulta direto no S3
- Pay-per-query (por TB escaneado)
- Integração com AWS Glue Catalog
- Suporta formatos: CSV, JSON, Parquet, ORC, Avro

Como Funciona

1. Dados armazenados no S3
2. Define schema no Glue Catalog
3. Executa queries SQL no Athena
4. Resultados salvos no S3

Não move dados - consulta in-place!

Preço: \$5.00 por TB de dados escaneados. Use formatos colunares (Parquet/ORC) para reduzir custos em até 90%!

Otimização de Performance e Custos

Formatos de Dados:

Formato	Tipo	Performance	Custo
CSV/JSON	Row-based	Lento	Alto
Parquet	Columnar	Rápido	Baixo
ORC	Columnar	Rápido	Baixo

Partição de Dados:

s3://bucket/data/year=2024/month=01/

Particionar por colunas frequentes
no WHERE reduz dados escaneados

Compressão:

- GZIP, Snappy, LZ4, ZSTD
- Reduz tamanho = menos custo
- Parquet ja inclui compressão
- Splittable para paralelismo

Casos de Uso e Integrações



Ad-hoc Analysis

Queries pontuais
em dados do data lake



Log Analysis

Analisar logs de
CloudTrail, ELB, S3



BI/Reporting

Dashboards com
QuickSight



ETL Light

CTAS para transformar
e salvar dados

Integrações com AWS:

AWS Glue: Data Catalog e ETL jobs

Amazon S3: Data source e output

QuickSight: Visualização/BI

Lambda: Trigger queries

Step Functions: Orquestração

CloudTrail: Análise de logs AWS

CTAS (Create Table As Select): Converte dados para Parquet e particiona automaticamente

Revisão: Pontos-chave para o Exame

1. O que é Athena

- Serverless SQL queries direto no S3
- Pay-per-query (\$5/TB escaneado)
- Integra com Glue Data Catalog

2. Otimização de custos

- Use Parquet/ORC (colunar) - ate 90% economia
- Particione dados por colunas do WHERE
- Comprima os dados (GZIP, Snappy)

3. Casos de uso

- Ad-hoc analysis em data lake
- Análise de logs (CloudTrail, ELB, S3)
- BI com QuickSight

LEMBRE-SE: Se precisa de 'SQL queries serverless em S3' ou 'analisar logs no S3' > pense Amazon Athena!